

基于动态专利嵌入表示的AI产业技术融合预测研究^{*}

张晓黎 匡 衡

(上海对外经贸大学统计与信息学院 上海 201620)

摘要:【目的】提出文本嵌入动态图神经网络的链路预测方法,旨在对人工智能领域技术创新的融合趋势进行建模与预测,揭示潜在的技术关联和创新路径。【方法】将专利摘要文本融入动态图神经网络的节点特征表示中,借助动态图神经网络的学习能力得到更准确的链路预测结果。【结果】以国内AI领域为例进行验证,相较于相似度模型和传统图表示学习模型,本文方法的AUC提升约0.06。【局限】由于嵌入维度过大,难以与图神经网络融合,专利摘要文本嵌入时未使用大语言模型。【结论】该方法预测准确度高,增强了对未来AI领域专利融合预测的可信度,是开展细粒度链路预测的一种有效方法。

关键词: 细粒度链路预测 技术融合 专利摘要 文本嵌入 动态图神经网络

分类号: TP391 G202

DOI: 10.11925/infotech.2096-3467.2023.1150

引用本文: 张晓黎, 匡衡. 基于动态专利嵌入表示的AI产业技术融合预测研究[J]. 数据分析与知识发现, 2025, 9(3): 96-105. (Zhang Xiaoli, Kuang Heng. Predicting AI Industry Technology Convergence Based on Dynamic Patent Embedding Representation[J]. Data Analysis and Knowledge Discovery, 2025, 9(3): 96-105.)

1 引言

开放式创新背景下,技术融合演化涉及知识、技术、应用和产业等阶段融合。在产业领域内和跨产业领域间表现为技术互补和技术集成。随着云计算、区块链和大语言模型等颠覆性技术的涌现,知识和应用深度交融,使得跨产业技术融合可能性大增^[1]。不断增强的技术互补性和累积效应突破产业间原有技术边界,在不同产业展现出差异化的融合模式,破坏和重塑企业生产能力,引发产业链的解构和重组,带动传统产业转型升级和新兴产业创新发展。

人工智能(Artificial Intelligence, AI)技术涵盖机器学习、语音图像视频识别、自然语言处理和专家系统。其技术融合表现为知识更新迭代快、新技术增长迅猛、技术融合速度快、跨产业融合机会多、经济效益好以及产业关联度强。人工智能正与人类生活接轨,对社会发展和国际竞争产生越来越大的影响^[2]。结

合人工智能产业技术融合现状,预测未来可能的融合方向,能提前把握新兴产业技术演进方向,发现更多创新机会。专利数据蕴含丰富的先进信息和前沿知识,是研究产业技术融合的最佳选择。国际专利分类法(International Patent Classification, IPC)是国际通用的专利文献分类和检索工具,可以量化技术元素的表示形式。大多数技术融合预测方法都基于专利IPC分类号^[3]的共现次数构建专利共现网络。

为提高专利共现网络链路预测的准确性,本研究提出了一种基于摘要文本嵌入动态图神经网络(Dynamic Graph Neural Network, DGNN)的细粒度链路预测方法。该方法以专利共现网络为基础,将专利摘要文本进行嵌入表示,依照专利时间期选取的不同设计了4种嵌入方式作为动态图神经网络输入的一部分,旨在将专利摘要中的潜在信息融入学习过程,从而更准确地挖掘人工智能产业未来的技术融合发展方向。

通讯作者(Corresponding author): 张晓黎(Zhang Xiaoli), ORCID: 0000-0001-5193-6069, E-mail: zhangxiaoli@suibe.edu.cn。

^{*}本文系上海市哲学社会科学规划课题(项目编号: 2019BGL003)的研究成果之一。

The work is supported by Shanghai Philosophy and Social Science Planning Projects (Grant No. 2019BGL003).

2 研究进展

基于专利共现的技术融合预测,对专利包含的多个分类号按照两两之间的共现次数构建网络。李慧等^[3]利用社会网络分析法的中间中心性和接近中心性识别关键融合技术,通过马尔可夫模型预测产业技术融合概率。王宏起等^[4]考虑多技术领域间的相互作用对技术融合的影响,采用静态相似度 Katz 指标预测中国电动汽车产业技术融合方向。刘晓燕等^[5]构建技术融合-组织合作多层网络,基于静态相似度指标考虑技术融合趋势识别未来合作关系。Lee 等^[6]利用专利引用信息分析通信领域的技术融合轨迹,为领域知识流动提供证据。这些方法对未来技术融合的预测主要基于当前网络拓扑结构,忽视技术网络演变的时序信息和专利文本信息。基于专利数据的粗粒度技术分类,只能在宽泛的技术层面得出预测结论,尚未深入技术领域细节。

文本表示是将文本信息转换为计算机可处理的向量形式。Word2Vec 模型^[7]通过训练神经网络处理语料,结合上下文信息将每个词语映射为具有 K 维实值的向量,相较于 One-Hot 向量表示,该方法解决了维度灾难问题。为进一步将这种思想延伸到长文档中, Kim 等^[8]借鉴 Word2Vec 思想,提出无监督的、将长文本转化为固定长度向量的 Doc2Vec 模型。张金柱等^[9]提出综合专利分类序列结构和文本语义表示的技术融合预测方法。网络结构和文本特征都会对技术融合产生影响,但每类特征对技术融合预测的贡献度不同^[10-11]。Seo 等^[12]使用聚类可能性、链接可能性和技术相似性作为输入特征,预测语义一致的技术主题之间的潜在技术融合。可见,在特定技术领域,需要学习不同特征对技术融合预测的贡献,综合利用网络 and 文本特征提高预测效果。

链路预测是指预测网络中任意两个节点之间出现连边的可能性,常被应用在社交网络、推荐系统和本体研究中,主要分为相似性度量和图表示学习。带权重相似度将连边权重加入网络局部相似度计算用于链路预测^[13-19],如 WCN (Weighted Common Neighbors)、WAA (Weighted Adamic-Adar)、WRA (Weighted Resource Allocation) 和 WJC (Weighted Jaccard Coefficient) 等。该类方法忽略远程节点即

不相邻且最小路径长度很大的节点之间形成链路的可能性。图表示学习将节点的网络拓扑属性转换为特征向量表示用于链路预测^[20-25],代表方法有 Deepwalk、LINE (Large-Scale Information Network Embedding)、SDNE (Structural Deep Network Embedding)、Node2Vec、Struc2Vec。图神经网络也是一种图表示学习,借助深度学习方法聚合节点特征。Hamilton 等^[26]通过可训练的邻居聚合函数扩展图卷积方法,提出空间域卷积方法 GraphSAGE 学习静态图上的节点特征。这些方法侧重对静态图的学习,图结构不随时间变化。

现实世界的关联关系变化快,网络本质上是动态的。动态链路预测应用在各种场景中,如预测未来一段时间的交通流量、企业间未来合作可能性等^[27]。动态图神经网络(DGNN)是处理动态图数据的神经网络模型,捕捉图结构随时间的变化,适应图中节点和边的增减,从而更好地处理时间序列数据和动态变化的数据。DGNN 主要分为堆叠型和集成型。DySAT^[28]是堆叠型 DGNN,对每个时间节点上的图进行表示学习,借助自注意力机制和循环神经网络学习数据中蕴含的时间信息。该方法虽然将时间纳入学习过程,但没有将时序融入图表示学习。EvolveGCN^[29]是集成型 DGNN,在图表示学习过程中利用循环神经网络更新表示学习的权重,纳入时序信息。图表示学习方法利用启发式算法,从给定网络自动捕捉和学习网络结构,避免复杂的网络特征提取工程,但仅侧重于学习网络拓扑结构,忽略技术本身的内部属性。现有链路预测研究尚缺乏有效纳入属性特征的图表示方法。

为解决上述问题,本文提出文本嵌入动态图神经网络的细粒度链路预测方法,引入动态图神经网络模型,研究技术节点间的动态网络拓扑关系,将属于技术节点的专利摘要特征融入动态图表示学习中,丰富网络表示的特征,能更加有效进行细粒度技术融合预测。

3 基于专利文本嵌入的动态图神经网络模型

首先,构建专利 IPC 共现网络,节点代表 IPC 号,链路代表节点之间的连接。链接权重表示两个 IPC 之间的重复出现情况。接着,利用动态图神经网络

模型对专利共现网络进行表示,构建在网络拓扑层面的节点属性表示。基于文本表示学习,分4种形式将节点对应的专利摘要文本时序地嵌入网络节点属性中,并结合其他可融入的属性。然后,通过模型计算节点之间未来产生链路的可能性。基于链路预测理论,设计技术融合预测指标与方法进行预测。最后,比较基于相似度、静态图表示学习和动态图表示学习等技术融合预测方法的性能。

3.1 专利共现网络

一个IPC号由部、大类、小类、大组和小组5部分组成。例如,IPC号H01L-002/042,H是部,01是大类,L是小类,002是大组,042是小组。IPC号前4位代表某一领域,前7位(简称IPC7)表示细分领域。一条专利申请可能会包含一个主IPC号和多个从IPC号,体现一条专利申请中的技术融合。在无向专利共现网络中,IPC7代表的技术领域表示网络中的节点,两个IPC7间的共现关系表示节点间的边。计算两个节点的共现频次与它们各自总出现频次的比率,即得到一个相对值,该相对值考虑了每个节点在整个数据集中的普及程度。

3.2 动态图神经网络模型

EvolveGCN^[29]是一种基于图卷积网络的动态

网络嵌入方法,可以有效地对与时间相关的网络进行表示学习和预测。其在多个动态网络数据集上的实验,均超过了多种基准方法,显示出较好的预测效果。本文采用EvolveGCN学习专利共现网络中的节点特征。在图卷积网络(Graph Convolutional Network, GCN)的基础之上,通过长短期记忆网络(Long Short-Term Memory, LSTM)对GCN参数更新,纳入时序动态信息,从而更好地学习专利共现网络特征,具体如公式(1)和公式(2)所示。

$$\mathbf{H}_t^{(l+1)} = \text{GCONV}(\mathbf{A}_t, \mathbf{H}_t^{(l)}, \mathbf{W}_t^{(l)}) = \sigma(\hat{\mathbf{A}}_t \mathbf{H}_t^{(l)} \mathbf{W}_t^{(l)}) \quad (1)$$

$$\mathbf{W}_t^{(l)} = \text{LSTM}(\mathbf{W}_{t-1}^{(l)}) \quad (2)$$

其中,下标 t 表示时间索引;上标 l 表示GCN层索引; $\mathbf{W}_t^{(l)}$ 表示GCN中 t 时刻第 l 层的参数矩阵; $\mathbf{H}_t^{(l)}$ 表示 t 时刻学习到的第 l 层网络节点的特征矩阵; \mathbf{A}_t 表示 t 时刻专利共现网络的邻接矩阵; $\hat{\mathbf{A}}_t = \mathbf{A}_t + \mathbf{I}$, \mathbf{I} 是单位矩阵。

参数学习过程如图1所示,网络输入为节点的度矩阵 \mathbf{T}_t 和邻接矩阵 \mathbf{A}_t ,将 \mathbf{T}_t 作为初始特征矩阵 $\mathbf{H}_t^{(0)}$ 。 σ 是除输出层以外的其他层激活函数,均采用ReLU函数作为激活函数。输出层对边进行链路预测,采用其他激活函数。

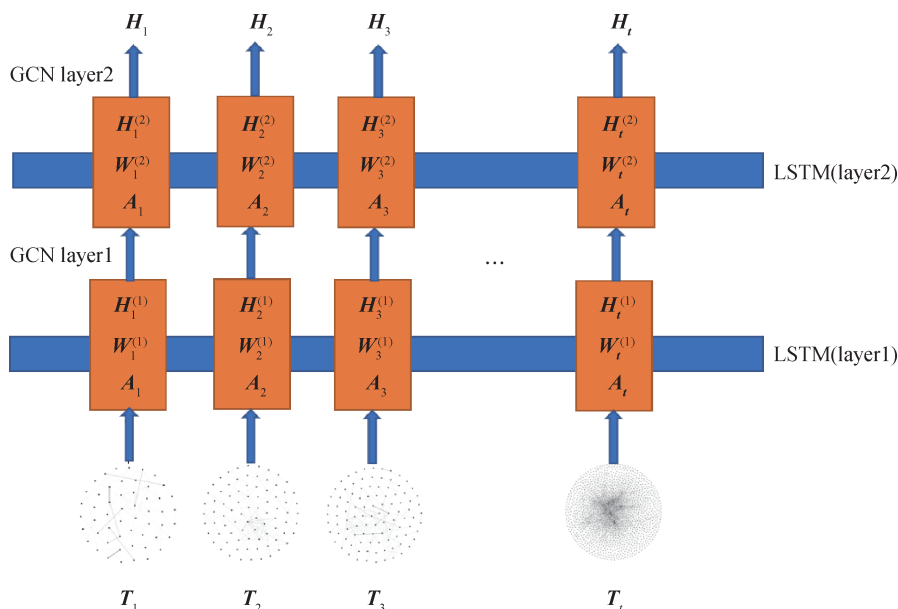


图1 EvolveGCN模型

Fig.1 EvolveGCN Model

3.3 专利文本嵌入

专利摘要通常包含对技术发展的描述、对专利申请人和技术应用的说明,可以揭示技术之间的联系和技术发展的轨迹。将专利摘要嵌入共现网络中,将其与网络结构信息相结合,以提高对技术领域的深入理解和分析。本文的专利摘要文本嵌入步骤如下:首先,利用 FudanNLP^[30] 进行去除停用词以及

分词操作,将每条专利摘要文本进行拆分。然后,利用预训练模型 Doc2Vec 进行词编码。同一 IPC 有多条专利时,将各条专利的嵌入进行平均池化,从而实现专利分类号的语义表示。最后,设计 4 种专利摘要嵌入图表示矩阵的方式,比较选出最优的专利摘要文本嵌入方式。专利摘要文本嵌入方式如图 2 所示。

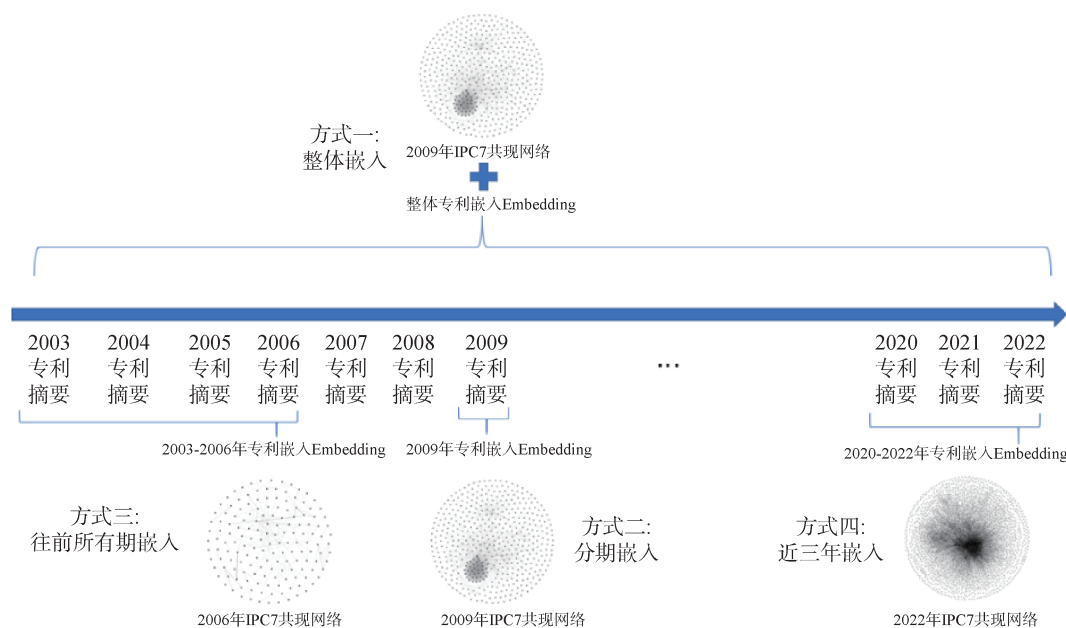


图 2 专利摘要文本嵌入方式

Fig.2 Text Embedding Methods for Patent Abstract

方式一:整体嵌入基于所有期的向量合并,即将所有期的专利数据按照 IPC 节点进行嵌入化操作,将整个专利文本嵌入特征矩阵 H'_{1-n} 与网络度矩阵 $H_i^{(0)}$ 拼接得到 $\tilde{H}_i^{(0)} = [H_i^{(0)}, H'_{1-n}]$, 输入模型训练。

方式二:分期嵌入基于当前的向量合并,即分别将每期对应的专利文本嵌入特征 H'_t 与网络度矩阵 $H_i^{(0)}$ 拼接得到 $\tilde{H}_i^{(0)} = [H_i^{(0)}, H'_t]$, 输入模型训练。

方式三:往前所有期嵌入将当前期及往前所有期的专利文本嵌入特征矩阵 H'_{1-t} , 与网络度矩阵 $H_i^{(0)}$ 拼接得到 $\tilde{H}_i^{(0)} = [H_i^{(0)}, H'_{1-t}]$, 输入模型训练。

方式四:近三年嵌入考虑专利的时效性,即从专利申请后的三年内,专利所代表的新兴技术是最有效的,所以当前期的特征矩阵 $\tilde{H}_i^{(0)} = [H_i^{(0)}, H'_{t-3-t}]$ 由网络度矩阵 $H_i^{(0)}$ 以及当前期前三年的专利文本嵌

入特征矩阵 H'_{t-3-t} 拼接而成。

4 实验与分析

4.1 数据预处理

实验数据来源于 incoPat 全球专利数据库,以主题方式检索申请地区为中国的人工智能产业专利。具体涉及基础层、技术层和应用层,共计 16 个一级产业,72 个二级产业。检索到相关专利数据共计 23 万条,覆盖范围为 2003 年至 2022 年。专利总量、融合专利量及其在人工智能产业中的占比情况如图 3 所示。

由图 3 可见,人工智能产业专利总量从 2003 年至今呈增长趋势,2015 年后增长更加迅猛。但融合专利量在 2020 年后才迅猛增加。融合占比在排除了总体专利数过少的因素影响后也呈现陡升趋势。




图3 2003-2022年AI产业专利总量、融合专利量及占比

Fig.3 Total AI Industry Patents, Fusion Patents and Proportions from 2003 to 2022

可见,我国人工智能产业早期呈现领域内高速发展,近期在技术融合推动下跨领域发展迅猛。未来,人工智能领域将会是颠覆性技术创新爆发、衍生涌现新质生产力的产业。因此,对我国人工智能产业的发展方向进行预测显得尤为重要。

4.2 相似度算法与图表示学习方法比较

衡量链路预测算法精准度的常用指标为ROC曲线下面积(Area Under Curve, AUC),即测试集中边的分数值比随机选择的一个不存在的边的分数值高的概率^[31]。每次随机从测试集中选取一条边与随机选择的不存在的边进行比较。如果测试集中边的分数值大于不存在的边的分数值,则加1分;如果两个分数值相等,则加0.5分。这样独立比较 n 次,如果有 n' 次测试集中边的分数值大于不存在的边的分数值,有 n'' 次两个分数值相等,那么定义 $AUC = \frac{n' + 0.5n''}{n}$ ^[19]。如果所有分数都是随机产生的,那么 $AUC=0.5$ 。因此, $AUC>0.5$ 的程度衡量了算法比随机选择方法精确的程度。

相似度算法与图表示学习方法的比较结果如表1所示。将2003-2022年的网络数据作为相似度指标的测试数据集,计算WAA、WCN、WJC和WRA相似度,且分别计算AUC指标。同时,比较图表示学

习方法LINE、Node2Vec、Struc2Vec和DeepWalk的AUC指标;还比较了基于GCN的时序网络模型EvolveGCN和DySAT,均采用默认参数。动态时序网络选取前8个网络作为训练集,中间8个网络作为验证集,最后3个网络作为测试集。

由表1可见,在专利共现网络中,静态图表示学习网络模型在网络规模很小的2003年和2004年表现一般,AUC指标小于0.5,比随机水平更差。而相似度算法在网络规模很小时也有高于0.5的AUC指标,说明相似度指标受到网络规模的影响较小。但是,在网络规模较大的2021年和2022年,图表示学习模型在AUC指标上略优于相似度指标模型。

4.3 基于专利文本嵌入的动态网络预测

原始专利文本包含很多并不具有一定意义但又出现在文本语料库中出现频率比较高的词语,如“本发明”“公开”等重复性词汇。这些词语经常出现在专利文本中,但是无法代表原始文本的具体语义信息,反而使数据维度增加,加大文本分类的难度。为提高文本分类的效果和精度,需要删除文本中的这类词,以减少对分类任务的影响。然后将收集到的专利摘要作为训练语料库的输入,利用Gensim包中的Doc2Vec预训练模型对原始语料库进行训练,构建了包含98 523个词汇的词库;并将10万条专利摘要

表 1 相似度算法与图表示学习方法比较

Table 1 Comparison of Similarity Algorithms and Graph Representation Learning Methods

方法	AUC	AUC _{t03}	AUC _{t04}	AUC _{t09}	AUC _{t10}	AUC _{t20}	AUC _{t21}	AUC _{t22}
WCN		0.622	0.623	0.711	0.641	0.851	0.822	0.810
WJC		0.635	0.612	0.710	0.710	0.859	0.831	0.829
WAA		0.545	0.623	0.683	0.700	0.814	0.840	0.837
WRA		0.556	0.709	0.698	0.750	0.815	0.832	0.816
DeepWalk		0.437	0.408	0.765	0.580	0.847	0.882	0.845
LINE		0.390	0.377	0.690	0.716	0.840	0.844	0.864
Node2Vec		0.419	0.418	0.857	0.623	0.833	0.830	0.842
Struc2Vec		0.403	0.412	0.671	0.789	0.861	0.821	0.843
EvolvGCN	0.865					0.841	0.842	0.865
DySAT	0.833					0.810	0.809	0.833

(注:仅展示 2003、2004、2009、2010、2020、2021、2022 年各个模型的 AUC 指标结果。)

作为输入,得到每个专利的嵌入表示。

为了提升模型预测效果,对主要参数进行调优实验。GCN 的层数是影响模型效果的重要因素。对比 EvolveGCN 中 GCN 层数分别为 1~3 时的模型效果,最终 GCN 层数为 2 时模型表现最佳。这是因为层数为 1 时,对网络结构的信息提取不充分;而层数超过 2 时,降低了模型的学习能力。模型中相关超参数的设置都经过反复实验,在链路预测任务中取得最好表现的取值,具体设置如表 2 所示。

表 2 模型参数设置

Table 2 Parameter Settings

参数名称	参数值	参数名称	参数值
学习率	0.01~0.001	Window_size	5
词向量维度	100	Dropout	0.2
隐藏层 1 维度	150	Loss 函数	Cross Entropy
隐藏层 2 维度	50	GCN 层数	2

分别对多种向量嵌入方式用链路预测方法定量评估模型效果。为了选取最佳嵌入方式,将第 3 节中设计的 4 种专利摘要嵌入方式进行模型效果层面比较,如表 3 所示。将效果最好的专利摘要向量表示和网络度矩阵拼接。

由表 3 可见,往前所有期的嵌入方式效果最佳,且相较于无专利文本嵌入方式 AUC 指标提升了 0.059。这是因为利用这种方式可以观察到完整的技术演化历程,对技术发展规律把握更为准确全面。采用整体所有期的方式则会有数据穿越。如果只采

表 3 专利摘要文本嵌入方式比较

Table 3 Comparison of Text Embedding Methods for Patent

Abstract		
方法	嵌入方式	AUC
方法一	整体	0.896
方法二	分期	0.877
方法三	往前所有期	0.924
方法四	近三年	0.892

用当前时间期的专利文本,只能反映某一时间点下的状态。采用近三年的专利数据虽然更加符合专利的申请授权周期,但也存在专利体现的信息不足的问题。因此,本文选取往前所有期的专利摘要表示嵌入方式,作为最终的链路预测方法,预测国内人工智能产业未来可能产生技术融合的细分领域。

4.4 中国人工智能产业技术融合预测结果

利用效果最佳的模型对 AI 领域专利共现网络 $t+1$ 期的专利共现网络进行预测。依照网络节点度中心性(图 4)、接近中心性与中间中心性排名前 5 节点的变化情况(图 5),对网络中的重要节点以及网络整体变化进行分析。同时,分析节点度中心性排名前三的领域未来会与哪些领域产生连边,试图发现未来热门领域的新兴融合方向。

(1) 未来 AI 领域共现网络节点中心性变化分析

由图 4 可见,未来主要技术领域的度中心性均有进一步提升,这说明上述技术领域的技术融合仍会继续增加。代表信息检索技术的 G06F16 发展最为迅猛,技术融合与其他类别的差距进一步加大。

G06F40代表的机器学习技术发展更加迅速,应用范围不断扩大,创新产出不断增加。G06F40类技术融合将会超过G06K9。而G06K9代表的图像处理技术进入发展平台期。在G06F40领域占据研发优势的机构(如百度),可进一步将机器学习算法与信息检索的技术融合,挖掘在特殊领域或传统产业的应用场景,实现差异化竞争。在G06K9领域占据研发优势的机构(如电子科技大学),可挖掘与机器学习、信息检索结合的图像处理技术应用场景,实现成果的产业应用和商业转化。


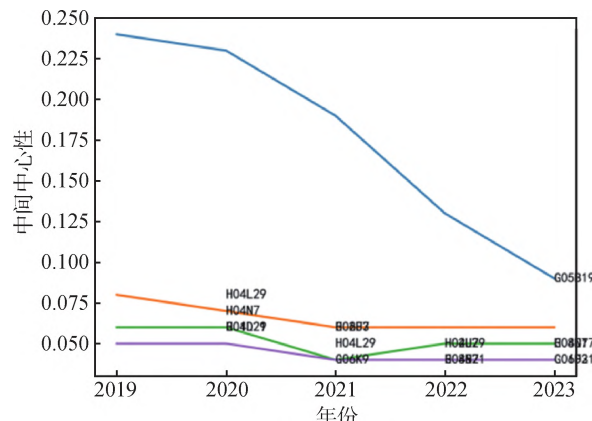



图4 主要AI领域的度中心性变化

Fig.4 The Trend of Degree Centrality in the AI Field

由图5可见,主要技术领域的中间中心性和接近中心性均趋于减小。这说明创新网络整体连通性增强,不再过度依赖中间节点。网络演化呈现技术细化、专业化和去中心化的发展趋势。这使得中国AI产业创新网络的抗风险能力增强,不再过度依赖单一或某几个技术。主要技术节点的控制力和影响力降低。例如,随着AI产业规模增大,一直是AI产业关键中间技术的G05B19(电力系统控制技术)对资源的控制力和对其他知识的影响力逐渐被削弱。这说明电力系统控制技术的研发主体更加分散,不再集中在少数企业。电网技术创新出现分散化趋势,技术垄断优势逐渐下降。在该领域处于研发领先地位的国家电网,应从资源控制型向合作共赢型转变,采用开放共享的创新模式引入外部创新资源,进行产学研深度协作,加速技术升级迭代,强化在新兴技术领域的优势。



(a) 中间中心性



(b) 接近中心性

图5 主要AI领域的中间中心性与接近中心性变化

Fig.5 The Trend of Betweenness Centrality and Closeness Centrality in the AI Field

(2) 主要科技领域的融合预测

从专利共现网络中选出度中心性排名前三的领域,分别为G06F16、G06N3和G06F40。G06F16是基于信息检索、数据库结构的相关领域,G06N3是基于生物学模型的计算机系统,G06F40是自然语言处理相关的领域。研究重点关注它们未来可能会产生技术融合的领域。对重点技术领域与其他可能出现连边的领域占比进行排名,前四领域如表4所示。

由表4可见,A47B代表的专利领域为桌子、写字台、办公家具、柜橱、抽屉、家具的一般零件,它与三个热门技术领域产生连边的结果最大。预测结果包含A47B1/00(按结构特点区分的桌子或写字台)、A47B17/00(写字台)、A47B21/00(适用于个人计算机工作站的桌或台)、A47B39/00(折叠式或拆收式

表4 重点技术领域未来可能融合的前四领域
Table 4 Top Four Potential Future Links in the Key Technological Fields

排名	G06F16	G06N3	G06F40
1	A47B	A47B	A47B
	0.126	0.151	0.163
2	B65G	B65G	H04W
	0.121	0.125	0.140
3	H04W	H04W	G08B
	0.119	0.122	0.132
4	A61B	G08B	G01N
	0.117	0.118	0.132

(注:小数代表该领域可能产生连边的数量占整个重点领域可能产生连边数量的比例。)

桌子等)。目前,智能家居多是与传统电器相结合的智能家电,与传统桌椅等家具结合较少。为实现未来全屋一体化智能,全屋智能行业的企业可以侧重布局相关领域。

未来与 G06F16 融合的重点领域有 A61B,其代表诊断、外科和鉴定等医疗相关领域。G06F16 派生的细分领域,为医学目标实时监测提供元数据,以及特征检索为医学实时诊断装置提供了未来融合的可能。

未来与 G06N3 融合的领域包含 B65G,其代表运输、储存和搬运等技术。细分领域有 B65G/19,代表工业车间上的运输流水线装置。这种融合将推动特殊场景下工业流水线机器人的智能化发展,实现传统工业设备与先进计算机系统和 AI 技术的有机结合。

未来与 G06F40 自然语言处理领域融合较多的领域有 G08B。该领域与自然语言处理可能融合的细分领域有 G08B3/00 触觉信号系统、G08B6/00 可听的信号装置或器件。自然语言处理领域方面的智能听说对话、生成上下文等可以和信号系统结合,形成特殊应用场景的多模态智能交互系统,或具有触觉和听觉的智能机器人等是未来 AI 领域的热点方向。

5 结 语

为了更好地预测人工智能产业未来融合发展方向,提高图表示学习模型的预测能力,更有效地学习

技术融合信息,本文提出基于时序的融合专利文本嵌入的动态图表示学习模型。直接对专利共现网络通过相似度算法或图表示学习模型进行学习,仅能获得网络拓扑结构信息。为了充分利用蕴含在专利数据中的丰富信息,将专利摘要文本进行表示学习。本文设计比较了 4 种摘要表示嵌入方法,希望在各个时间层面上学习专利摘要中的隐含信息。表现最好的方法为当前期及历史所有摘要表示拼接的嵌入方法。本文方法相较于相似度算法和单一的图表示学习方法均有一定提升。

本文研究仍存在以下不足:首先,节点属性局限在专利摘要上,对于原始专利数据的其他属性利用度不够。后续研究可以重点关注其他信息;其次,文本嵌入方法只利用了 Doc2Vec。大语言模型由于维度过大、难以嵌入,因此本文没有使用。后续研究将高效利用大语言模型更好地学习专利文本信息,进一步提升预测精确度和决策支持度。

参考文献:

- [1] 张治河,高中一. 人工智能产业创新生态系统模型的构建与分析[J]. 科研管理, 2023, 44(10): 10-21. (Zhang Zhihe, Gao Zhongyi. Construction and Analysis of the Model of an AI Industry Innovation Ecosystem[J]. Science Research Management, 2023, 44(10): 10-21.)
- [2] Zhang Z G, Luo T Y. Knowledge Structure, Network Structure, Exploitative and Exploratory Innovations[J]. Technology Analysis & Strategic Management, 2020, 32(6): 666-682.
- [3] 李慧,孟玮,徐存真. 基于专利知识流网络的技术融合分析——以石墨烯领域为例[J]. 现代情报, 2021, 41(5): 121-130. (Li Hui, Meng Wei, Xu Cunzhen. Research on Technology Convergence Based on Patent Knowledge Flow Network——A Case Study of Graphene[J]. Journal of Modern Information, 2021, 41(5): 121-130.)
- [4] 王宏起,夏凡,王珊珊. 新兴产业技术融合方向预测: 方法及实证[J]. 科学学研究, 2020, 38(6): 1009-1017. (Wang Hongqi, Xia Fan, Wang Shanshan. Forecast on Technological Fusion Direction of Emerging Industries: Method and Empirical Research[J]. Studies in Science of Science, 2020, 38(6): 1009-1017.)
- [5] 刘晓燕,张淑伟,单晓红. 面向技术融合的合作伙伴识别研究[J]. 科学学研究, 2023, 41(12): 2164-2174. (Liu Xiaoyan, Zhang Shuwei, Shan Xiaohong. Research on Partner Identification for Technology Convergence: Based on Multi-Layer Network Link Prediction[J]. Studies in Science of Science, 2023, 41(12): 2164-

- 2174.)
- [6] Lee C J, Kogler D F, Lee D. Capturing Information on Technology Convergence, International Collaboration, and Knowledge Flow from Patent Documents: A Case of Information and Communication Technology [J]. Information Processing & Management, 2019, 56(4): 1576-1591.
 - [7] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space [C]//Proceedings of the 1st International Conference on Learning Representations. 2013.
 - [8] Kim J, Lee S. Forecasting and Identifying Multi-technology Convergence Based on Patent Data: The Case of IT and BT Industries in 2020[J]. Scientometrics, 2017, 111(1): 47-65.
 - [9] 张金柱, 李溢峰. 专利分类序列和文本语义表示视角下的技术融合预测研究[J]. 情报学报, 2022, 41(6): 609-624. (Zhang Jinzhu, Li Yifeng. Technology Convergence Prediction by the Semantic Representation of Patent Classification Sequence and Text[J]. Journal of the China Society for Scientific and Technical Information, 2022, 41(6): 609-624.)
 - [10] Newman M E J. Clustering and Preferential Attachment in Growing Networks[J]. Physical Review E, 2001, 64(2): 025102.
 - [11] Adamic L A, Adar E. Friends and Neighbors on the Web[J]. Social Networks, 2003, 25(3): 211-230.
 - [12] Seo W, Afifuddin M. Developing a Supervised Learning Model for Anticipating Potential Technology Convergence Between Technology Topics [J]. Technological Forecasting and Social Change, 2024, 203: 123352.
 - [13] Zhou T, Lü L Y, Zhang Y C. Predicting Missing Links via Local Information[J]. The European Physical Journal B, 2009, 71(4): 623-630.
 - [14] Barabási A L, Albert R. Emergence of Scaling in Random Networks[J]. Science, 1999, 286(5439): 509-512.
 - [15] Martínez V, Berzal F, Cubero J C. A Survey of Link Prediction in Complex Networks [J]. ACM Computing Surveys, 2016, 49(4): 69.
 - [16] Tan F, Xia Y X, Zhu B Y. Link Prediction in Complex Networks: A Mutual Information Perspective [J]. PLoS One, 2014, 9(9): e107056.
 - [17] Wang M Y, Yu G, Yu D R. Measuring the Preferential Attachment Mechanism in Citation Networks[J]. Physica A: Statistical Mechanics and its Applications, 2008, 387(18): 4692-4698.
 - [18] Lü L Y, Zhou T. Link Prediction in Weighted Networks: The Role of Weak Ties[J]. Europhysics Letters, 2010, 89(1): 18001.
 - [19] Lü L, Zhou T. Link Prediction in Complex Networks: A Survey [J]. Physica A: Statistical Mechanics and Its Applications, 2011, 390(6): 1150-1170.
 - [20] Perozzi B, Al-Rfou R, Skiena S. DeepWalk: Online Learning of Social Representations [C]//Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2014: 701-710.
 - [21] Tang J, Qu M, Wang M Z, et al. Line: Large-Scale Information Network Embedding [C]//Proceedings of the 24th International Conference on World Wide Web. 2015: 1067-1077.
 - [22] Wang D X, Cui P, Zhu W W, et al. Structural Deep Network Embedding[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 1225-1234.
 - [23] Grover A, Leskovec J. Node2Vec: Scalable Feature Learning for Networks[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016: 855-864.
 - [24] Ribeiro L F R, Saverese P H P, Figueiredo D R. Struc2Vec: Learning Node Representations from Structural Identity[C]//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2017: 385-394.
 - [25] Bogaerts T, Masegosa A D, Angarita-Zapata J S, et al. A Graph CNN-LSTM Neural Network for Short and Long-Term Traffic Forecasting Based on Trajectory Data[J]. Transportation Research Part C: Emerging Technologies, 2020, 112: 62-77.
 - [26] Hamilton W L, Ying R, Leskovec J, et al. Inductive Representation Learning on Large Graphs[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. 2017: 1025-1035.
 - [27] 卢志刚, 陈倩. 动态供应链网络中企业合作关系的链路预测[J]. 计算机工程与应用, 2022, 58(2): 265-273. (Lu Zhigang, Chen Qian. Link Prediction of Enterprise Cooperation Relationship in Dynamic Supply Chain Network[J]. Computer Engineering and Applications, 2022, 58(2): 265-273.)
 - [28] Sankar A, Wu Y H, Gou L, et al. DySAT: Deep Neural Representation Learning on Dynamic Graphs Via Self-attention Networks[C]//Proceedings of the 13th International Conference on Web Search and Data Mining. 2020: 519-527.
 - [29] Pareja A, Domeniconi G, Chen J, et al. EvolveGCN: Evolving Graph Convolutional Networks for Dynamic Graphs[C]//Proceedings of the 34th AAAI Conference on Artificial Intelligence. 2020: 5363-5370.
 - [30] Qiu X P, Zhang Q, Huang X J. FudanNLP: A Toolkit for Chinese Natural Language Processing[C]//Proceedings of the 51st Annual Meeting of the Association for Computational Linguistics: System Demonstrations. 2013: 49-54.
 - [31] 杨凯凯, 钱宇华, 马国帅, 等. 端点活跃度对链接预测的影响研究[J]. 小型微型计算机系统, 2019, 40(6): 1280-1285. (Yang Kaikai, Qian Yuhua, Ma Guoshuai, et al. Influence of Endpoint Activity on Link Prediction[J]. Journal of Chinese Computer Systems, 2019, 40(6): 1280-1285.)

作者贡献声明:

匡衡:实现研究方案,数据收集,撰写论文;
张晓黎:设计与修改研究思路和方案,论文修改及定稿。

支撑数据:

[1] 匡衡. 中国企业 AI 专利数据集. DOI: 10.57760/sciencedb.j00133.00333.

利益冲突声明:

所有作者声明不存在利益冲突关系。

收稿日期:2023-11-10

收修改稿日期:2024-08-15

Predicting AI Industry Technology Convergence Based on Dynamic Patent Embedding Representation

Zhang Xiaoli Kuang Heng

(School of Statistics and Information, Shanghai University of International Business and Economics, Shanghai 201620, China)

Abstract: [Objective] This study proposes a link prediction method based on dynamic graph neural networks for text embedding, aiming to model and predict the integration trend of technological innovation in artificial intelligence. It also reveals potential technological connections and innovation pathways. [Methods] We integrated patent abstract texts into the node feature representations of the dynamic graph neural networks. By leveraging the learning capabilities of dynamic graph neural networks, we obtained more accurate link prediction results. [Results] Using the domestic AI field as an example, the method achieved an AUC index improvement of approximately 0.06 compared to similar and traditional graph representation learning models. [Limitations] Due to the high dimensionality of embeddings, it is difficult to integrate with graph neural networks. We did not use large language models for embedding patent abstracts. [Conclusions] The proposed method has a high predictive accuracy, enhancing the credibility of AI patent convergence forecasting. It is an effective way to predict fine-grained links.

Keywords: Fine-Grained Link Prediction Technological Convergence Patent Abstract Text Embedding Dynamic Graph Neural Network